

LeGO-LOAM:Lightweight and Ground-Optimized Lidar Odometry and Mapping on Variable Terrain

轻量化和地面优化的可变地形激光雷达里程计和建图

作者：Tixiao Shan

参考：https://blog.csdn.net/qq_21842097/article/details/88319580?spm=1001.2014.3001.5506

<https://blog.csdn.net/zkk9527/article/details/116160508?spm=1001.2014.3001.5506>

https://blog.csdn.net/avenger_fang/article/details/123270901?spm=1001.2014.3001.5506

0、 摘要

我们提出了一种轻量化和地面优化的可变地形激光雷达里程计和建图方法，即 LeGO-LOAM，用于地面车辆实时六自由度姿态估计。LeGO-LOAM 是轻量级的，因为它可以在低功耗嵌入式系统上实现实时姿态估计。LeGO-LOAM 是地面优化的，因为它在分割和优化步骤中利用了地面的存在。我们首先应用点云分割来滤除噪声，并提取特征以获得独特的平面和边缘特征。然后，两步 Levenberg-Marquardt 优

化方法使用平面和边缘特征来解决连续扫描中六自由度变换的不同分量。我们使用从地面车辆的可变地形环境收集的数据集，将 LeGO-LOAM 的性能与最先进的方法 LOAM 进行了比较，并表明 LeGO-LOAM 在降低计算量的情况下实现了类似或更好的精度。我们还将 LeGO-LOAM 集成到一个 SLAM 框架中，以消除漂移引起的姿态估计误差，这是使用 KITTI 数据集进行测试的。

1、介绍

在智能机器人的能力中，地图构建和状态估计是最基本的先决条件之一。人们致力于利用基于视觉和基于激光雷达的方法实现实时 6 自由度同时定位和建图 (SLAM)。尽管 **基于视觉的方法在回环检测中具有优势**，但如果将其用作唯一的导航传感器，则其对照明和视点变化的敏感性可能会使这种能力不可靠。另一方面，基于激光雷达的方法即使在夜间也能发挥作用，而且许多 3D 激光雷达的高分辨率允许在大孔径下远距离捕捉环境的精细细节。因此，本文着重于使用 3D 激光雷达来支持实时状态估计和建图。

寻找两个激光雷达扫描之间转换的典型方法是迭代最近点 (ICP) [1]。通过在逐点水平上找到对应关系，ICP 迭代地对齐两组点，直到满足停止标准。当扫描大量的点时，ICP 会遭受 **高昂的计算成本**。已经提出了 ICP 的许多变体，以提高其效率和准确性[2]。[3] 引入了点对平面 ICP 变体，该变体将点与局部平面面片相匹配。广义 ICP[4]提出了一种匹配两次扫描的局部平面面片的方法。此外，一些 ICP 变体

利用并行计算提高了效率[5]–[8]。

基于特征的匹配方法吸引了更多的关注，因为它们通过从环境中提取代表性特征而需要更少的计算资源。这些特征应该适合于有效的匹配和不变的观点。已经提出了许多检测器，例如点特征直方图 (PFH) [9] 和视点特征直方图 (VFH) [10]，用于使用简单有效的技术从点云中提取这些特征。[11] 中介绍了一种使用 Kanade Tomasi 角检测器从点云中提取通用特征的方法。[12] 中讨论了从密集点云提取线和平面特征的框架。

还提出了许多使用特征进行**点云配准**的算法。[13] 以及[14]提出了一种关键点选择算法，该算法在局部簇中执行点曲率计算。然后使用所选关键点来执行匹配和位置识别。通过**将点云投影到距离图像上**并分析深度值的二阶导数，[15] 从具有高曲率的点中选择特征以进行匹配和位置识别。假设环境由平面组成，[16] 中提出了一种基于平面的配准算法。户外环境，例如森林，可能限制这种方法的应用。[17] 中介绍了一种特别为 Velodyne 激光雷达设计的领线段 (CLS) 方法。CLS 使用扫描的两个连续“环”中的点随机生成线。因此，生成两条线云并用于注册。然而，这种方法受到随机生成线的挑战。[18] 中提出了一种**基于分割的配准算法**。**SegMatch** 首先将分割应用于点云。然后根据特征值和形状直方图为每个片段计算特征向量。使用随机林 (forest) 来匹配两次扫描的片段。虽然这种方法可以用于在线姿态估计，但它只能在 1Hz 左右提供定位更新。

[19]和[20]中提出了一种低漂移实时激光雷达里程计和建图 (LOAM) 方法。LOAM 执行点特征到边缘/平面扫描匹配, 以找到扫描之间的对应关系。通过计算点在其局部区域中的粗糙度来提取特征。选择具有高粗糙度值的点作为边缘特征。类似地, 具有低粗糙度值的点被指定为平面特征。通过将估计问题新颖地划分为两个单独的算法来实现实时性能。一种算法以高频率运行, 以低精度估计传感器速度。另一种算法在低频率下运行, 但返回高精度的运动估计。将这两个估计融合在一起, 以产生高频率和高精度的单个运动估计。LOAM 的最终精度是 KITTI 里程计基准站点上仅使用激光雷达的估计方法获得的最佳结果[21]。

在这项工作中, 我们致力于为配备 3D 激光雷达的地面车辆提供可靠、实时的六自由度姿态估计, 其方式可以在小型嵌入式系统上高效实现。出于几个原因, 这样的任务并非微不足道。许多无人地面车辆 (UGV) 由于其尺寸有限, 没有悬架或强大的计算单元。在可变地形上行驶的小型无人值守地面车辆经常遇到非平稳运动, 因此, 采集的数据经常失真。由于具有有限重叠的大运动, 在两次连续扫描之间也很难找到可靠的特征对应。此外, 从 3D 激光雷达接收到的大量点对使用有限的机载计算资源进行实时处理提出了挑战。

当我们为这些任务实现 LOAM 时, 当 UGV 以平滑的运动和稳定的特征运行时, 我们可以获得低漂移的运动估计, 并且有足够的计算资源支持。然而, 当计算资源有限时, LOAM 的性能会恶化。由于需

要计算密集 3D 点云中每个点的粗糙度，因此在轻量级嵌入式系统上特征提取的更新频率不能总是跟上传感器更新频率。UGV 在嘈杂环境中的运行也给 LOAM 带来了挑战。由于激光雷达的安装位置通常靠近小型 UGV 上的地面，因此来自地面的传感器噪声可能会持续存在。例如，草的范围返回可能导致高粗糙度值。因此，可以从这些点提取不可靠的边缘特征。类似地，还可以从从树叶返回的点提取边缘或平面特征。这样的特征对于扫描匹配通常是不可靠的，因为在两次连续扫描中可能看不到相同的草叶。使用这些特征可能会导致不准确的配准和较大的漂移。

因此，我们提出了一种轻型和地面优化 LOAM (LeGO-LOAM)，用于在复杂地形环境中对 UGV 进行姿态估计。LeGO-LOAM 是轻量级的，因为实时姿态估计和建图可以在嵌入式系统上实现。执行点云分割以丢弃可能表示地面分离后不可靠特征的点。LeGO-LOAM 也是地面优化的，因为我们为姿态估计引入了两步优化。在第一步中，从地面提取的平面特征用于获得 $[t_z, \theta_{roll}, \theta_{pitch}]$ 。在第二步中，通过匹配从分割的点云提取的边缘特征来获得变换的其余部分 $[t_x, t_y, \theta_{yaw}]$ 。我们还集成了执行闭环检测以校正运动估计漂移的能力。本文的其余部分组织如下。第二节介绍了用于实验的硬件。第三节详细介绍了所提的方法。第四节介绍了在各种户外环境下进行的一系列实验。

2、系统硬件

本文提出的框架使用 Velodyne VLP-16 和 HDL-64E 3D 激光雷达

收集的数据集进行了验证。VLP-16 测量范围可达 100m,精度为 $\pm 3\text{cm}$ 。它的垂直视野 (FOV) 为 $30^\circ(\pm 15^\circ)$ 水平 FOV 为 360° 。16 通道传感器的垂直角度分辨率为 2° 。水平角分辨率从 0.1° 至 0.4° 基于旋转速率。在本文中,我们选择了 10Hz 的扫描速率,这提供了 0.2° 的水平角分辨率。HDL-64E (在本工作中通过 KITTI 数据集进行了探索) 的水平视野也为 360° 但还有 48 个通道。HDL-64E 的垂直视野为 26.9° 。

本文使用的 UGV 是 Clearpath 豺狼。它由 270 瓦时的锂电池供电,最大速度为 2.0m/s,最大有效载荷为 20kg。豺狼还配备了低成本惯性测量单元 (IMU),即 CH Robotics UM6 方位传感器。

所提出的框架在两台计算机上进行了验证:一台 Nvidia Jetson TX2 和一台带有 2.5GHz i74710MQ CPU 的笔记本电脑。Jetson TX2 是一款嵌入式计算设备,配备了 ARM Cortex-A57 CPU。选择笔记本电脑 CPU 以匹配[19]和[20]中使用的计算硬件。本文所示的实验仅使用这些系统的 CPU。

3、轻量化激光雷达里程计和建图

A、系统概述

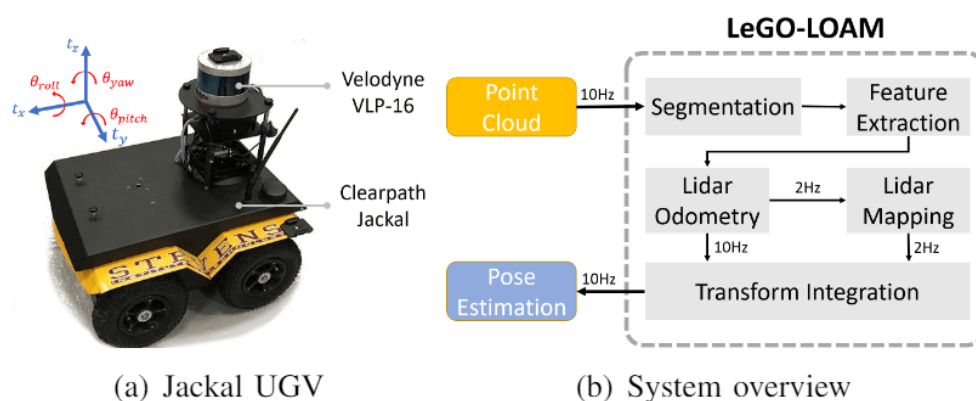


图 1: LeGO-LOAM 的硬件和系统概述

拟议框架的概述如图 1 所示。该系统接收来自 3D 激光雷达的输入并输出 6 自由度姿态估计。整个系统分为五个模块。首先，分割，获取单个扫描的点云，并将其投影到距离图像上进行分割。然后将分割的点云发送到特征提取模块。然后，激光雷达里程计使用从前一模块提取的特征来找到与连续扫描相关的变换。这些特征在激光雷达地图中得到进一步处理，并将其登记到全局点云地图中。最后，变换积分模块将激光雷达里程计和激光雷达建图模块的姿态估计结果进行融合，并输出最终的姿态估计。相对于[19]和[20]的原始广义 LOAM 框架，所提出的系统寻求提高地面车辆的效率和准确性。下面将介绍这些模块的详细信息。

B、分割

设 $P_t = \{p_1, p_2, \dots, p_n\}$ 是在时间 t 获取的点云，其中 p_i 是 P_t 中的

点。 P_t 首先被投影到距离图像上。由于 VLP-16 的水平和垂直角度分辨率为 0.2° 和 2° ，投影距离图像的分辨率为 1800 乘 16, P_t 中的每个有效点 p_i 现在由距离图像中的唯一像素表示。与 p_i 相关联的距离值 r_i 表示从对应点 p_i 到传感器的欧几里德距离。由于斜坡地形在许多环境中很常见，我们不认为地面是平坦的。在分割之前，对距离图像进行逐列评估，这可以被视为地平面估计[22]，用于地点提取。在此过程之后，可能表示地面的点被标记为地面点，而不用于分割。

然后，将基于图像的分割方法[23]应用于距离图像，以将点分组为多个簇。来自同一簇的点将被指定一个唯一的标签。注意，地面点是一种特殊类型的集群。将分割应用于点云可以提高处理效率和特征提取精度。假设机器人在嘈杂的环境中运行，小物体（例如树叶）可能会形成微不足道的不可靠特征，因为在两次连续扫描中不太可能看到相同的树叶。为了使用分割的点云执行快速可靠的特征提取，我们省略了少于 30 个点的聚类。分割前后点云的可视化如图 2 所示。原始点云包括许多点，这些点是从可能产生不可靠特征的周围植被获得的。




图 2：噪声环境中扫描的特征提取过程。原始点云如（a）所示。在（b）中，红色点标记为地面点。其余的点是分割后保留的点。在（c）中，蓝色和黄色点表示 \mathbb{F}_e 和 \mathbb{F}_p 中的边缘和平面特征。在（d）中，绿色和粉色点分别表示 \mathbb{F}_e 和 \mathbb{F}_p 中的边缘和平面特征。

在这一过程之后，**只有可能代表大型物体的点（图 2 (b))，例如树干和地面点被保留以供进一步处理。**同时，只有这些点保存在距离图像中。我们也获得**每个点的三个属性**：(1) 其作为地面点或分段点的标签，(2) 其在距离图像中的列和行索引，(3) 其距离值。这些属性将在以下模块中使用。

C、特征提取

特征提取过程类似于[20]中使用的方法。然而，我们**不是从原始点云中提取特征，而是从地面点和分割点中提取特征。**设 S 是距离图像的**同一行的连续 p_i 点的集合**。 S 中的一半点位于 p_i 的两侧。在本文中，我们将 $|S|$ 设置为 10。使用分割期间计算的范围值，我们可以评估 S 中点 p_i 的粗糙度，

$$c = \frac{1}{|S| \cdot \|r_i\|} \left\| \sum_{j \in S, j \neq i} (r_j - r_i) \right\|. \quad (1)$$

为了从所有方向均匀地提取特征，我们将距离图像水平划分为几个相等的子图像。然后，我们根据粗糙度值 c 对子图像每行中的点进行排序。与 LOAM 类似，我们使用阈值 c_{th} 来区分不同类型的特征。我们称 c 大于 c_{th} 为边缘特征的点和 c 小于 c_{th} 为平面特征的点。然后，从子图像中的每一行中选择不属于地面的具有最大值 c 的 n_{F_e} 个边缘特征点 (40 个)。以相同的方式选择具有最小值 c 的 n_{F_p} 个平面特征点 (80 个) (可以是地面点或分割点)。见图 2 (d)。




图 2：噪声环境中扫描的特征提取过程。原始点云如 (a) 所示。(b) 中，红色点标记为地面点。其余的点是分割后保留的点。(c) 中，蓝色和黄色点表示 F_e 和 F_p 中的边缘和平面特征。

(d) 中，绿色和粉色点分别表示 F_e 和 F_p 中的边缘和平面特征。

设 F_e 和 F_p 是来自所有子图像的所有边缘和平面特征的集合。这

些特征如图 2 (d) 所示。然后，我们从子图像中的每一行提取不属于地面的具有最大 c 的 n_{F_e} 个边缘特征 (2 个)。类似地，我们从子图像中的每一行提取具有最小 c 的 n_{F_p} 个平面特征 (4 个), 必须是地面点。设 F_e 和 F_p 为该过程中所有边缘和平面特征的集合。在这里，我们有 $F_e \subset \mathbb{F}_e$ 和 $F_p \subset \mathbb{F}_p$ 。 F_e 和 F_p 的特征如图 2 (c) 所示。在本文中，我们将 360° 距离图像划分为 6 个子图像。每个子图像的分辨率为 300 乘 16。 n_{F_e} 、 n_{F_p} 、 $n_{\mathbb{F}_e}$ 和 $n_{\mathbb{F}_p}$ 分别选择为 2、4、40 和 80。

D、激光里程计

激光雷达里程计模块估计两次连续扫描之间的传感器运动。通过执行点对边和点对平面扫描匹配，可以找到两次扫描之间的转换。换句话说，我们需要从上一次扫描的特征集 \mathbb{F}_e^{t-1} 和 \mathbb{F}_p^{t-1} 中找到 F_e^t 和 F_p^t 中点的对应特征。为了简洁起见，在[20]中可以找到这些对应关系的详细步骤。

然而，我们注意到，可以进行一些更改以提高特征匹配的准确性和效率：

- (1) **标签匹配：** 由于 F_e^t 和 F_p^t 中的每个特征在分割后都用其标签进行编码，因此我们只能从 \mathbb{F}_e^{t-1} 和 \mathbb{F}_p^{t-1} 中找到具有相同标签的对应关系。对于 F_p^t 中的平面特征，只有在 \mathbb{F}_p^{t-1} 中标记为地面点的点才用于查找作为对应的平面贴片 (patch)。对于 F_e^t 中的边缘特征，其对应的边缘线位于分段聚类的 \mathbb{F}_e^{t-1} 中。以这种方式找

到对应关系可以帮助提高匹配精度。换句话说，在两次扫描之间更可能找到相同对象的匹配对应。这一过程还缩小了潜在的候选者。

- (2) **两步 L-M 优化**：在[20]中，将当前扫描的边缘和平面特征点之间的距离及其与前一次扫描的对应关系的一系列非线性表达式编译为单个综合距离向量。应用 Levenberg-Marquardt (L-M) 方法来找到两次连续扫描之间的最小距离变换。

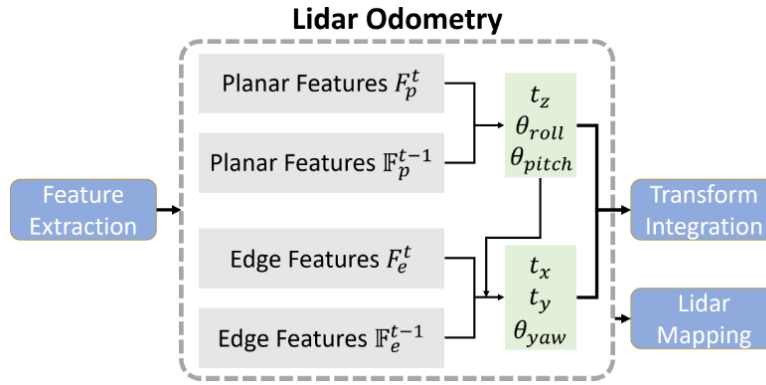


图 3：激光雷达里程计模块的两步优化。首先通过匹配从地面点提取的平面特征来获得 $[t_z, \theta_{roll}, \theta_{pitch}]$ 。然后使用从分段点提取的边缘特征来估计 $[t_x, t_y, \theta_{yaw}]$ ，同时应用 $[t_z, \theta_{roll}, \theta_{pitch}]$ 作为约束。

我们在这里介绍了一种两步 L-M 优化方法。最优变换 T 分为两个步骤：(1) 通过匹配 F_p^t 中的平面特征及其在 F_p^{t-1} 中的对应关系来估计 $[t_z, \theta_{roll}, \theta_{pitch}]$ 。应该注意的是，虽然 $[t_x, t_y, \theta_{yaw}]$ 也可以从第一个优化步骤中获得，但它们不太准确，不用于第二个步骤。最后，通过融合 $[t_z, \theta_{roll}, \theta_{pitch}]$ 和 $[t_x, t_y, \theta_{yaw}]$ 找到两个连续扫描之间的 6D 变换。通过使用所提出的两步优化方法，我们观察到，在计算时间减少约 35% 的情况下，可以实现类似的

精度（表 III）。

E、激光雷达建图

激光雷达建图模块将 $\{\mathbb{F}_e^t, \mathbb{F}_p^t\}$ 中的特征与周围点云图 \bar{Q}^{t-1} 相匹配，以进一步细化姿态变换，但运行频率较低。然后再次使用 L-M 方法获得最终变换。我们让读者参考[20]中的描述，了解详细的匹配和优化过程。

LeGO-LOAM 的主要区别在于如何存储最终点云地图。我们保存每个单独的特征集 $\{\mathbb{F}_e^t, \mathbb{F}_p^t\}$ ，而不是保存单个点云地图。设 $M^{t-1} = \{\{\mathbb{F}_e^1, \mathbb{F}_p^1\}, \dots, \{\mathbb{F}_e^{t-1}, \mathbb{F}_p^{t-1}\}\}$ 是保存所有以前特征集的集合。 M^{t-1} 中的每个特征集也与扫描时传感器的姿态相关。那么 \bar{Q}^{t-1} 可以通过两种方式从 M^{t-1} 获得。

在第一种方法中， \bar{Q}^{t-1} 通过选择传感器视野中的特征集来获得。为了简单起见，我们可以选择传感器姿态在传感器当前位置 100m 以内的特征集。然后将选定的特征集转换并融合到单个周围地图 \bar{Q}^{t-1} 中。这种地图选择技术与[20]中使用的方法类似。

我们还可以将姿态图 SLAM 集成到 LeGO-LOAM 中。每个特征集的传感器姿势可以建模为姿势图中的节点。特征集 $\{\mathbb{F}_e^t, \mathbb{F}_p^t\}$ 可被视为此节点的传感器测量值。由于激光雷达建图模块的姿态估计漂移非常低，我们可以假设在短时间内没有漂移。这样， \bar{Q}^{t-1} 可以通过选择时间最近的一组特征集来形成，即

$\bar{Q}^{t-1} = \{\{\mathbb{F}_e^{t-k}, \mathbb{F}_p^{t-k}\}, \dots, \{\mathbb{F}_e^{t-1}, \mathbb{F}_p^{t-1}\}\}$, 其中 k 定义 \bar{Q}^{t-1} 的大小。

然后, 可以使用 L-M 优化后获得的变换来添加 \bar{Q}^{t-1} 中新节点和所选节点之间的空间约束。我们可以通过执行**闭环检测**来进一步消除该模块的漂移。在这种情况下, 如果使用 ICP 在当前特征集和先前特征集之间找到匹配, 则会添加新的约束。然后, 通过向优化系统(如[24])发送姿态图来更新传感器的估计位姿。注意, 只有第四节 (D) 中的实验使用这种技术来创建其周围地图。

5、结论和讨论

LeGO-LOAM, 这是一种轻量级和地面优化的激光雷达里程计和建图方法, 用于在复杂环境中执行无人地面车辆的实时姿态估计。LeGO-LOAM 是轻量级的, 因为它可以用于嵌入式系统并实现实时性能。LeGO-LOAM 还对地面进行了优化, 利用了**地面分离、点云分割和改进的 L-M 优化**。在此过程中, 会**过滤掉可能代表不可靠特征的无价值点**。两步 L-M 优化分别计算姿势变换的不同分量。在室外环境中收集的一系列 UGV 数据集上对所提出的方法进行了评估。结果表明, 与最先进的 LOAM 相比, LeGO-LOAM 可以达到类似或更好的精度, LeGO LOAM 的计算时间也大大减少。未来的工作包括探索其~~在其他类型车辆上的应用~~。

尽管 LeGO-LOAM 特别针对地面车辆的姿态估计进行了优化, 但其应用可能会扩展到其他车辆, 例如**无人机 (UAV)**, 只需稍作改动。当将 LeGO-LOAM 应用于无人机时, 我们**不会假设扫描中存在地面**。

扫描的点云将在没有地面提取的情况下被分割。对于 F_e 、 \mathbb{F}_e 和 \mathbb{F}_p 的选择，特征提取过程相同。 F_p 中的特征将从所有分割点中选择，而不是从标记为地面点的点中提取 F_p 的平面特征。然后将使用原始的 L-M 方法来获得两次扫描之间的转换，而不是使用两步优化方法。尽管这些变化后计算时间会增加，但 LeGO-LOAM 仍然有效，因为分割后在嘈杂的室外环境中省略了大量点。估计的特征对应关系的准确性可以提高，因为它们从分割中受益。此外，使用 LeGO-LOAM 在线执行闭环检测的能力使其成为长时间导航任务的有用工具。